

Datos, esquema canónico y preprocesado

1. Datasets y su papel

1.1. CICIDS2017 (principal)

- es la base moderna del proyecto
- se usan sus 8 CSV oficiales (`src/load_cicids2017.py`)
- define el espacio de observación actual

Versiones del dataset Existen dos versiones locales:

Versión	Ruta	Trackeada en git	Descripción
Curada	<code>datasets/CICIDS2017/*.csv</code>	Sí	Columnas con riesgo de leakage o redundar antes de la ingesta. Es la que carga el adaptador.
Raw	<code>datasets/CICIDS2017/Raw_dataset/</code>	No (en <code>.gitignore</code>)	Exports CSV originales de CICFlowMeter. Todas las columnas originales preservadas.

El adaptador (`src/load_cicids2017.py`) aplica limpieza adicional en tiempo de carga independientemente de qué versión se use. La política anti-leakage en código es la fuente de verdad autoritativa. La versión curada reduce la superficie de ingesta pero no reemplaza las protecciones en código.

1.2. NSL-KDD (histórico)

- sirve como benchmark histórico
- mantiene valor didáctico para evolución del proyecto
- su mapeo al esquema canónico es muy parcial (`NSL_KDD_TO_CANON`)

2. Decisión arquitectónica clave: esquema canónico

Archivo: `src/canonical_schema.py`

Se define una lista fija `FEATURES_CANON` de **76 features flow-based**. Esto garantiza que cada posición del vector tenga siempre el mismo significado.

2.1. Observación final

- 76 valores de features
- 76 valores de máscara de missingness
- total: **152 dimensiones**

3. Máscara de missingness (semántica)

- 1 = presente/válida
- 0 = ausente o imputada

Esto ayuda a no confundir “dato real” con “dato rellenado”.

4. Política anti-leakage

`load_cicids2017.py` elimina columnas propensas a leakage:

- IPs
- timestamps
- Flow ID
- puertos directos como proxy de etiqueta

Razonamiento: si el modelo aprende atajos espurios, las métricas offline pueden inflarse artificialmente y fallar en generalización real.

5. Preprocesado en CICIDS2017

Pipeline principal en `load_cicids2017.py`:

1. carga por chunks
2. localización robusta de columna de etiqueta
3. coerción numérica
4. $\text{inf} \rightarrow \text{NaN} \rightarrow \text{fillna}(0)$ en features
5. mapeo a canónico + máscara
6. split (`random` o `day`)
7. `StandardScaler` (fit en train, transform en test)

6. Modos de split y por qué importan

6.1. `random`

- estratificado 80/20
- útil para iterar rápido
- puede sobreestimar generalización

6.2. `day`

- train y test en grupos de días/CSV distintos
- más exigente y más cercano a escenario real

6.3. `exact CSV`

- usado en leave-one-exact-CSV-out
- deja fuera un CSV real completo por fold

7. Puntos finos que conviene dominar

- En CICIDS2017, los NaN se rellenan antes de mapear; la máscara captura sobre todo disponibilidad/validez tras mapping, no “histórico crudo” completo de missingness por celda.
- El `StandardScaler` se aplica a toda la observación (incluida máscara), así que la red recibe máscara escalada, no bits puros 0/1.