

Phase 2: laboratorio, inferencia y riesgos abiertos

1. Qué es exactamente Phase 2 hoy

Phase 2 es **inferencia offline** sobre flujos extraídos de tráfico de laboratorio.
Entrada mantenida:

- `scripts/predict_real_traffic_v2.py`

No incluye todavía bloqueo activo inline.

2. Flujo operativo resumido

1. generar/capturar tráfico en lab privado
2. extraer flujos
3. mapear al esquema canónico
4. aplicar pipeline robusto
5. predecir PERMIT/BLOCK
6. guardar artefactos de run

3. Endurecimiento técnico de la v2

3.1. Clipping por percentiles (pre-scaling)

- función: `apply_percentile_clipping` (`src/scaling_utils.py`)
- recorta features crudas a $[p_{\text{low}}, p_{\text{high}}]$ aprendidos en train

3.2. Clipping por z-score (post-scaling)

- función: `apply_z_clipping`
- limita valores escalados a $[-\text{max_z}, +\text{max_z}]$

3.3. Diagnósticos

`predict_real_traffic_v2.py` calcula y exporta estadísticos de z-score para vigilar domain shift.

4. Artefactos esperados de cada run Phase 2

En runs/phase2/<RUN_ID>/:

- config.json
- metrics.json
- predictions.csv
- diagnostics.json (si se exporta)

5. Hallazgo central de Phase 2 (honesto)

Hay runs comprometidos con comportamiento muy distinto en benign-only. Esto obliga a evitar sobrepromesas y a citar siempre el RUN_ID al hacer afirmaciones.

Mensaje sólido:

- la pipeline está técnicamente lista
- la robustez en tráfico real sigue siendo el principal problema científico/ingenieril abierto

6. Laboratorio privado y seguridad operacional

Referencias: docs/gcp_lab.md, docs/phase2_plan.md, lab/docker/*

Principios:

- red aislada
- no escaneo fuera de lab
- control estricto de acceso SSH
- no exponer secretos ni datasets sensibles en repo

7. Qué faltaría para pasar a bloqueo activo

1. estabilidad consistente en benign, ataque y mixto
2. umbrales operativos de FP/FN aceptables por caso de uso
3. procedimiento de rollback y supervisión humana
4. pruebas de seguridad operacional antes de automatizar bloqueo